

基于两大资金行业选择的 SVR 模型多因子选股 与 RSRS 择时策略

报告简介

策略介绍：本团队基于两大资金构建资金指标筛选行业、SVR 模型进行机器学习，筛选优质股票标的，构建股票池，同时采取 RSRS 择时策略，以及逐步减仓和阈值止损的方式进行风险管理，最大限度获得利润。

模型构建：本策略通过构造基于北向资金、主动资金的资金指标筛选行业，Alphalens 筛选有效因子，多维度地对因子进行有效性检验，相关性检验。至此，即完成了因子池的构建。使用 SVR 模型对训练集进行学习，通过参数调整，提高预测胜率，对股票排序，构建股票池，并运用 RSRS 择时模型选择买卖时机。

实证结果：我们以 2020 年 1 月 1 日到 2021 年 7 月 28 日的沪市 300 与深市 300 股票池的数据进行回测，回测结果策略收益明显跑赢了大盘，表明我们的策略具有良好的适用性。

创新及亮点：

在行业选择上，我们采用了北向资金、主动资金作为行业选择的重要资金，对两大资金的不同指标进行测试筛选，以求筛选出更好的行业赛道。

在选股上，使用了较高预测精度以及较强适用性的模型，即 SVR 作为选股的模型，并且运用了 Alphalens 作为因子分析框架，其优点在于可以批量的测试每个因子的性能，极大的拓宽了投资者的思路，提高回测结果的正确性和稳定性。

在风险控制方面，使用了 ATR 指标来衡量市场波动性，根据市场、个股的波动来决定是否加仓或减仓，达到逐步加减仓的效果，以控制仓位和风险。

目录

1. 量化投资策略概述	6
1.1 量化选股思路	7
1.2 量化择时思路	7
1.3 风险控制思路	7
2. 基于资金指标的行业选择	8
2.1 研究背景	8
2.2 北向资金行业配置能力实证分析	8
2.2.1 北向资金风格分析	8
2.2.2 北向资金在行业选择上超越市场表现	9
2.3 主动资金行业配置能力实证分析	14
2.3.1 主动资金的定义	14
2.3.2 主动资金在行业选择上超越市场表现	14
2.4 复合因子配置行业	18
2.4.1 复合因子设置	18
2.4.2 复合因子组合权重测试	19
3. 基于 SVR 算法的多因子模型选股	20
3.1 多因子模型构建	20
3.1.1 因子样本选择	21
3.1.2 数据预处理	22
3.1.3 单因子有效性检验	24
3.1.4 因子独立性检验	30

3.2 基于 SVR 算法的多因子模型构建	31
3.2.1 算法简介.....	31
3.2.2 算法的理论.....	32
3.2.3 支持向量回归的理论优势	32
3.2.4 模型实现.....	33
3.2.5 模型选股实际运用.....	33
4. 利用 RSRS 判断阻力支撑状况的择时策略	34
4.1 相关概念	34
4.2 阻力支撑状况	34
4.3 策略实现	36
4.4 参数调整	37
4.5 策略效果	37
5 风险控制优化	38
5.1 仓位管理与风险控制	38
5.2 优化结果	39
6 策略回测:	40
参考文献.....	42
附录.....	42

图目录

图 1.1	策略构建流程图.....	6
图 2.1	北向资金累计净买入.....	8
图 2.2	北向资金流入行业统计.....	9
图 2.3	北向资金各周频指标回测结果.....	11
图 2.4	北向资金各月频指标回测结果.....	12
图 2.5	不同周期指标对比.....	12
图 2.6	两周频指标对比.....	14
图 2.7	主动资金各周频指标回测.....	16
图 2.8	主动资金各月频指标回测.....	17
图 2.9	不同权重对比.....	19
图 2.10	北向资金占比为 0.85 多头组合收益.....	20
图 3.1	有效因子筛选流程.....	21
图 3.2	不同调仓周期下的 IC 绝对值.....	26
图 3.3	部分因子 IC 序列情况.....	27
图 3.4	因子分层效果检测.....	29
图 3.5	反转特例.....	30
图 3.6	因子相关系数矩阵.....	31
图 4.1	牛市中高 β 值对应市场走势示例.....	35
图 4.2	熊市中高 β 值对应市场走势示例.....	35
图 4.3	牛市中低 beta 值对应市场走势示例.....	36
图 4.4	熊市中低 beta 值对应市场走势示例.....	36
图 5.1	未加风险控制回测图.....	39
图 5.2	加入风险控制回测图.....	39
图 6.1	策略短期回测.....	40
图 6.2	长期策略回测.....	41

表目录

表 2.1	北上资金指标选取及构建方式.....	9
表 2.2	各指标数据.....	13
表 2.3	主动资金指标选取及构建方式.....	15
表 2.4	指标数据分析.....	18
表 2.5	回测结果分析.....	20
表 3.1	候选因子表.....	22
表 3.2	因子 t 值	24
表 3.3	t 值分位数数据	25
表 3.4	不同类因子的 IC 绝对值.....	26
表 3.5	挑选出的因子名称.....	28
表 3.6	最终选定因子表.....	31
表 3.7	SVR 模型结果.....	34
表 4.1	参数测试.....	37
表 5.1	风控回测对比表.....	40
表 6.1	短期回测表.....	40
表 6.2	长期策略回测表.....	41

1. 量化投资策略概述

本策略主要分为四块，基于资金指标的行业选择、SVR 算法模型选股，基于 RSRs 模型择时，以及风险控制。本报告先通过北向资金、主动资金构建的资金指标筛选行业、SVR 算法模型排序来构建择时所操作的股票池，再通过 RSRs 择时模型，进行对买卖点的判断，然后补充风险控制对策略进行调整优化，最后对整体在不同行情下进行回测，验证策略的有效性。

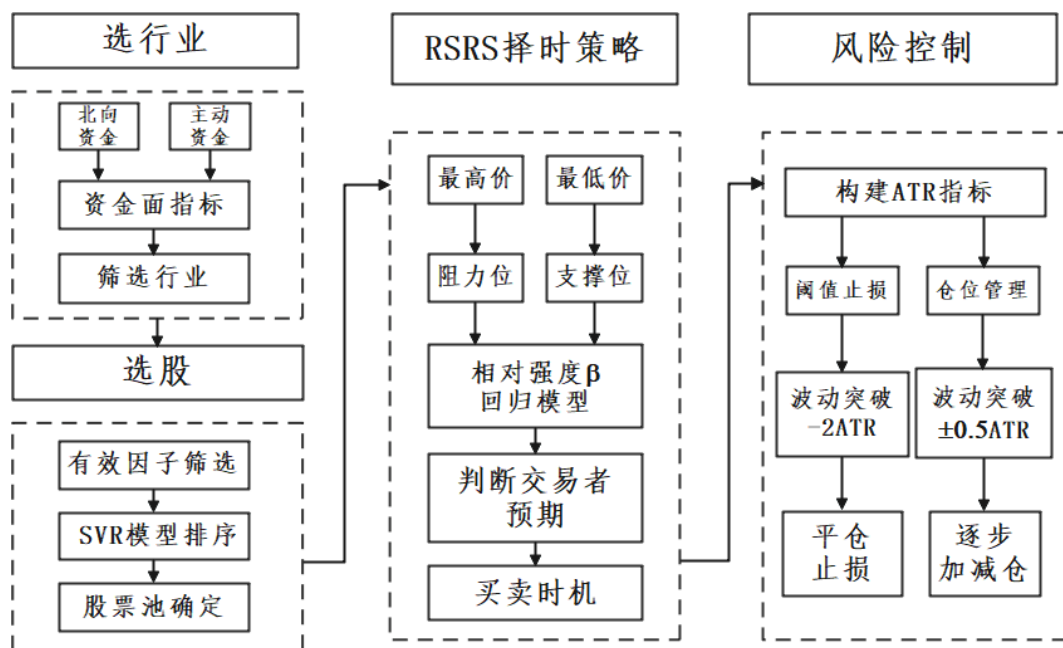


图 1.1 策略构建流程图

1.1 量化选股思路

本报告通过北上资金、主动资金构造的资金面指标筛选行业，**Alphalens** 筛选有效因子，通过 IC 分析、分层回测法等维度对因子进行有效性检验，再进行相关性检验，完成因子池的构建。使用 SVR 模型对训练集进行学习，预测未来股票收益，构建股票池。

1.2 量化择时思路

本报告选择 **RSRS** 模型进行择时交易，将股票的最高、最低价分别作为阻力和支撑位，建立线性回归模型，通过参数调整，选择能带来最高收益率的参数，并通过回归模型判断交易者对市场的预期，判断买卖时机。

1.3 风险控制思路

受到海龟交易思想的启发，本策略基于市场波动性来进行仓位管理和风险控制。通过构建 ATR 指标以及加减仓单位，来量化市场或者个股的波动性。当股价的波动幅度突破 ATR 指标的设定倍数值时，以单位进行加减仓位。同时也设定最低下限，当价格波动突破下限则彻底空仓标的资产。

该策略通过以逐步建仓的方式对仓位进行管理，以单位建仓量 *amount* 限制单次建仓金额，控制单笔交易的风险，进而达到仓位管理与风险控制的目的。

2. 基于资金指标的行业选择

2.1 研究背景

资金向来是推动市场发生变化的直接推动力。资金流动的变化代表了一方投资者当前对市场的预期观点。由于不同来源的资金所对应的投资者不同，其反映的投资情绪以及投资需求也有明显的不同，因此对不同来源的资金我们应当从中挖掘出不同的规律。

2.2 北向资金行业配置能力实证分析

从 2019 年以来，全市场最引人注目的资金就是北向资金。北向资金，通常是指通过香港市场流入 A 股的香港资金和国际资金。

2.2.1 北向资金风格分析




图 2.1 北向资金累计净买入

由上图所示，北向资金不断向 A 股市场流入，在 A 股的活跃度显著增加，对市场的影响也在不断提升。可见，北向资金已成为 A 股市场不可忽视的重要资金来源。再加上它“聪明钱”的称号，市场情绪的波动也逐渐受到北向资金流向的影响。




图 2.2 北向资金流入行业统计

截至 2021 年 7 月 16 日,根据申万一级 28 个行业分类,北向资金持有行业板块前五名分别是食品饮料、医药生物、电气设备、银行、家用电器。在板块配置上,北向资金偏好消费板块,且近年来偏好较稳定。

2.2.2 北向资金在行业选择上超越市场表现

1. 指标构建

本文基于北上资金每日的持股交易明细,从长短期角度切入,分别以月频或周频为时间跨度,以收益率和相对强度为评价标准,以申万一级作为行业分类标准,构建了 4 个与其持仓特征或交易行为有直接关联的行业选择指标,指标的构建方式如表所示:

表 2.1 北上资金指标选取及构建方式

指标	指标计算公式
持仓规模	$holding_mv = \sum_{i=1}^n close_i * holding_vol_i$
持仓规模占比	$holding_ratio = \frac{holding_mv}{industry_liquid_mv}$
流量	$holding_flow_i = holding_mv_i - holding_mv_{i-1}$
流量比率	$holding_flow_ratio = \frac{holding_mv_i - holding_mv_{i-1}}{holding_mv_{i-1}}$

(1) 持仓规模：

持仓规模是北上资金在行业上持有的流通市值，代表着北向资金的历史偏好，是北向资金投资国内市场的长期结果。

(2) 持仓规模占比：

持仓规模占比避免了大市值行业的高持仓规模特征对策略的影响，以便合理地对比北上资金在不同行业之间的历史偏好。

(3) 流量：

资金的流动刻画了北上资金对某个行业偏好的变化，流入（流出）越大，表明北上资金近期对某个行业越看好，短期内的边际变化可以理解为北上资金在行业上的择时。

(4) 流量比率：

为资金流量占所属行业的比值。不同行业体量之间存在明显的差异，流通市值可能不是一个数量级，高流量有时并不能代表北上资金的真实情绪。

2.周频调整

我们选取上述四种指标在过去一周的 top5 行业，按周度进行调仓，分别按照等权和非等权构建多头组合进行回测。以上证指数作为基准，观察各指标是否具有行业选择能力。

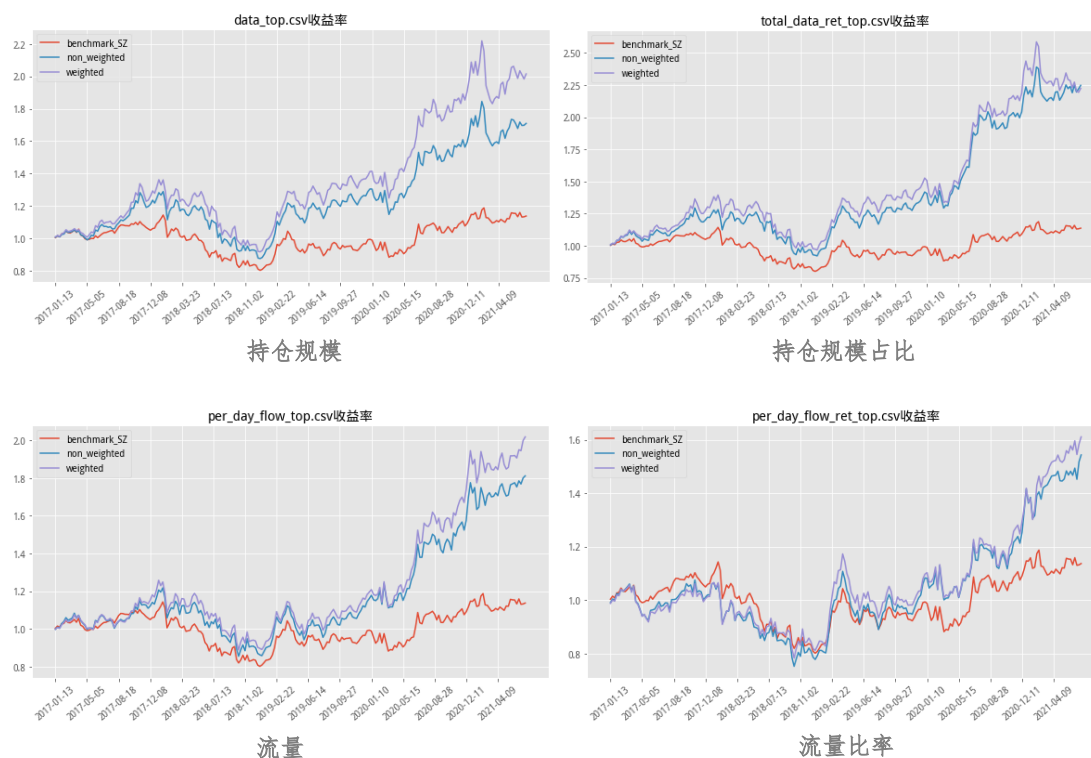


图 2.3 北向资金各周频指标回测结果

上图可以看出，“持仓规模”、“持仓规模占比”、“流量”，三大指标在 2017 年至 2021 年 7 月中旬均能获得良好的行业配置超额收益，而“流量比率”指标在 2017 年至 2019 年年中一直表现不佳，运行于基准收益率下方，直至 2019 年年中出现好转。

在周度调仓中，“持仓规模”和“持仓规模占比”都能取得 2.1 以上的收益率，“持仓规模占比”甚至一度达到 2.5 左右，但是二者之间的优势区分并不明显。

3.月频调整

我们选取过去一个月北向资金净流入 top5 行业，然后月度调整，分别按照等权和非等权进行回测。



图 2.4 北向资金各月频指标回测结果

“持仓规模”“持仓规模占比”两大指标月度数据的等权非等权收益率分离度良好，根据行业 top 排名的非等权组合比等权有更好的收益，两者非等权收益率大于等权大于基准，可以说明，月频调整的北向资金在此标准下也具备存在行业配置能力。再者可以观察到，“流量”“流量比率”指标等权与非等权收益率粘合度高，同时“流量比率”指标在 2020 年前收益均低于基准收益，因此这两个指标在月度调仓的条件下并不适合作为合理的指标。

4. 周期选择




图 2.5 不同周期指标对比

通过对于不同调仓周期的数据进行对比，以“持仓规模”指标为例。周度调整下，“持仓规模”指标等权与非等权收益粘合、交叉，月度调整下的收益率曲线分离度更好，非等权曲线一直运行于等权收益率上方。

表 2.2 各指标数据

指标	夏普比率	最大回撤	收益率	跑赢市场期数
持仓规模	1.066	32.7%	2.015	223
持仓规模占比	1.067	30.7%	2.223	224
流量	0.985	30.2%	1.976	51
流量比率	0.862	29.5%	2.094	51

可见，在不考虑手续费的基础上，周度指标相较于月度在收益率上高出 0.039，夏普比率高出 0.081，有优势，但是并不明显。若考虑手续费，周度的收益率优势极其容易被高额的手续费所吞噬。

同时，需要注意的是，在“持仓规模占比”月度数据中，近期的收益率曲线出现下滑，究竟是选择“持仓规模”还是“持仓规模占比”指标，应该对二者在今年的表现进行更加详细的分析。

5. 本年度指标状况分析

对于“持仓规模”“持仓规模占比”指标，我们无法直接从历史收益率中判别孰优孰劣，考虑到 21 年初股市的连续下跌，北向资金也出现较大回撤。所以，我们对二者在今年的周度表现进行特别提取分析。




图 2.6 两周频指标对比

“持仓规模”“持仓规模占比”二者在年初时都与基准收益率发生交叉，“持仓规模”在 2021 年 6 月 11 日后出现转折，临近 7 月，非等权行业收益出现 45° 掉头向上的良好趋势，推测市场资金面开始回暖，北上资金流入加大。而“持仓规模占比”指标相较落后，非等权行业收益率长期运行在基准收益下方。

因此，月度“持仓规模”更具有行业选择能力以及获取稳定超额收益能力，所以在北向资金中，最终选定月度“持仓规模”作为行业选择指标

2.3 主动资金行业配置能力实证分析

2.3.1 主动资金的定义

我们使用了主动流入资金作为衡量国内资金偏好的指标。市场中一般存在着大量的挂单，主动买入是指投资者主动去成交已经存在的卖单，相反的，主动卖出指的是投资者主动去成交已经存在的买单。顾名思义，主动流入资金能够体现市场交易的力量对比、资金偏好。

我们通过检测主动流入资金，构建主动资金指标来对国内投资者资金偏好进行观察，分析其是否具有行业选择能力。

2.3.2 主动资金在行业选择上超越市场表现

1. 指标构建

表 2.3 主动资金指标选取及构建方式

指标	指标计算公式
流入	$industry_inflow_i = \sum_j^n act_buy$
流入比率	$inflow_ratio_i = \frac{industry_inflow_i}{industry_market_cap_i}$
净流入	$net_inflow_i = \sum_i^n act_buy - \sum_i^n pas_buy$
净流入比率	$net_inflow_ratio_i = \frac{net_inflow_i}{industry_market_cap_i}$

(1) 流入：

一个行业的主动买单金额，包含特大单、大单、中单三种数额的主动交易数量级。统计行业主动买入单成交金额，能够反应资金在不同行业的动向，短期的流动可以理解为国内主动资金在行业上的择时。

(2) 流入比率：

流入金额占该行业流通市值的比率，与北上资金流量比率相同，由于不同行业之间本身存在体量的巨大差异，流入比率能够消除“流量”指标存在量纲的不足。

(3) 净流入：

股票同时存在主动买单与主动卖单，净流入即主动买单金额减去主动卖单金额，相比“流入”指标，“净流入”扣除主动卖单金额，是多空力量对比的结果。具体定义为：

个股的主动净流入资金=个股的主动买入成交额-个股的主动卖出成交额。

(4) 净流入比率：

净流入金额占行业市值的比率，同理消除行业市值差异。

2.周频调整

我们按周度进行调仓，分别选取上述四种指标前一周排名前五的行业作为本期持仓，分别以等权非等权构建多头组合进行回测。以上证指数作为基准，观察各指标是否具有行业选择能力。

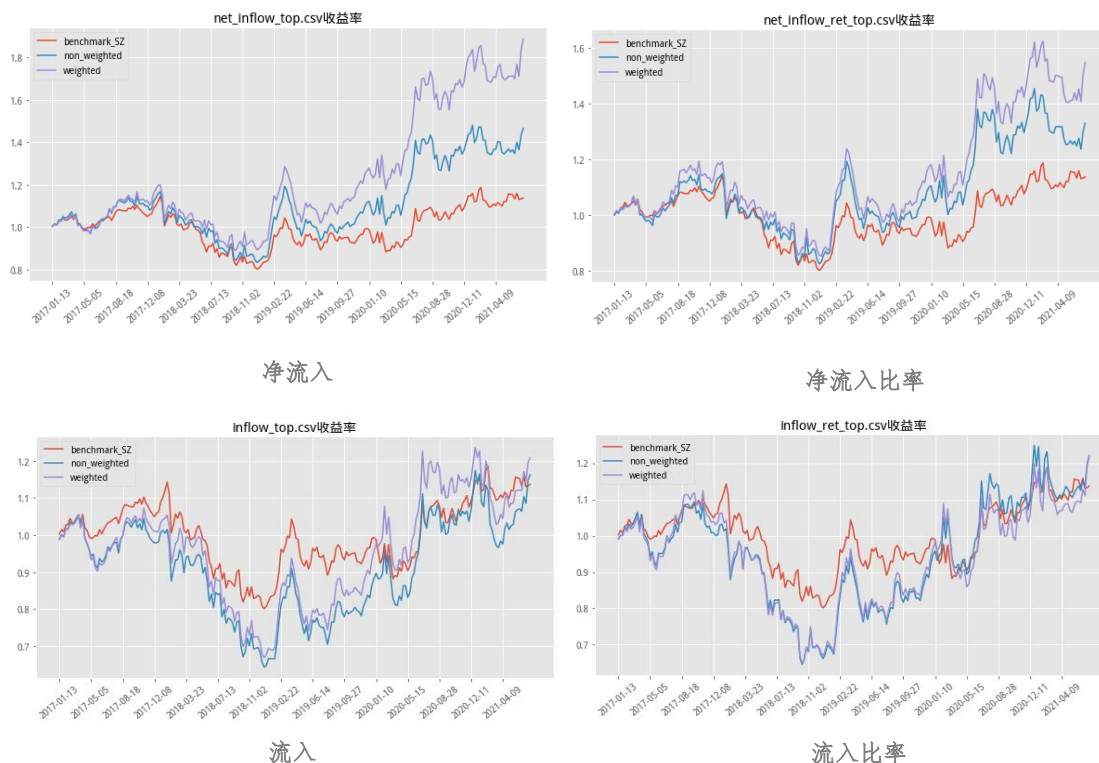


图 2.7 主动资金各周频指标回测

“净流入”指标回测中，非等权整体优于等权买入，并优势逐渐增大。并且两者与基准的差距也逐渐拉大，具有较好的分层现象，表明此指标拥有行业选择能力。

“净流入比率”指标回测中，非等权买入整体优于等权买入，但优势并没有“净流入指标”表现优异。两者与基准的差距也逐渐拉大，具有较好的分层现象，表明此指标拥有行业选择能力。

“流入”指标回测中，非等权买入整体优于等权买入。但 2020 年 1 月 10 号之前，无论是等权还是非等权买入都跑不过基准，即便存在一段时间反超基准，但长期来看没有持续的超额收益能力，故剔除。

“流入比率”指标回测中，非等权买入和等权买入的情况不相上下。并且大部分时间非等权买入都落后于基准收益，故剔除。

3.月频调整

我们按月度进行调仓，分别选取上述四种指标前一月排名前五的行业作为本期持仓，分别以等权非等权构建多头组合进行回测。以上证指数作为基准，观察各指标是否具有行业选择能力。

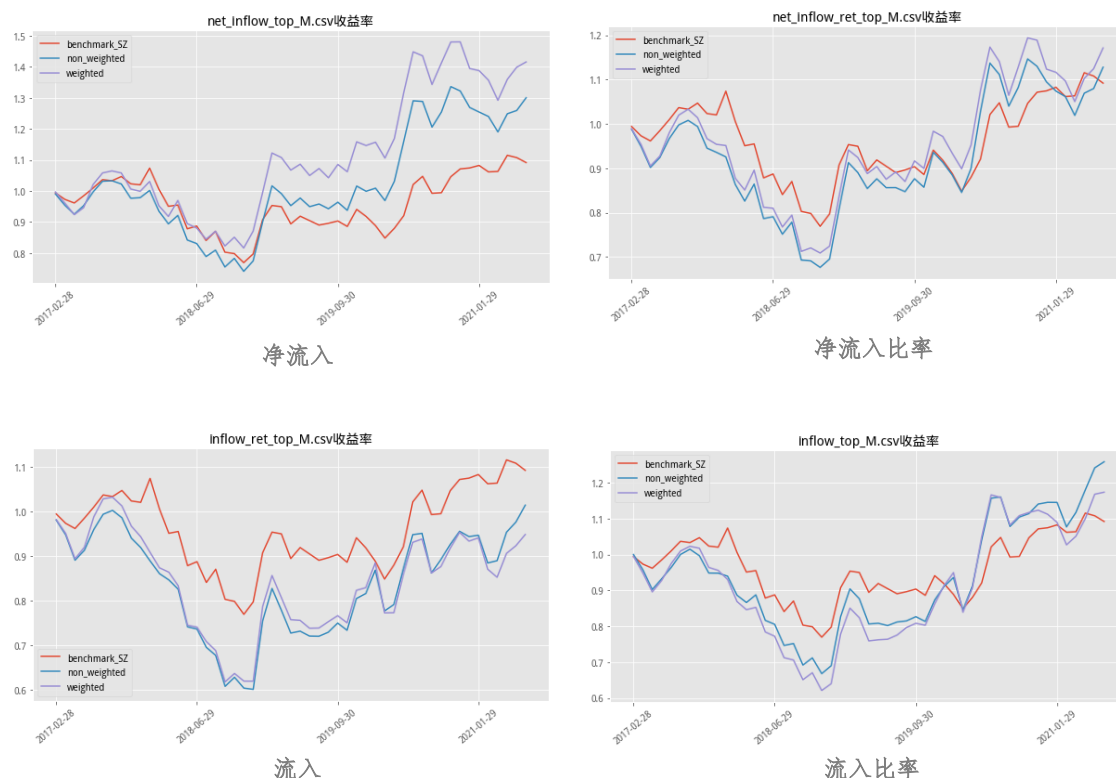


图 2.8 主动资金各月频指标回测

“净流入”指标回测中，非等权买入整体优于等权买入。虽然前期非等权买入与基准不相上下，但从 2019 年开始，非等权买入与基准的差距逐渐拉大，具有较好的分层现象，表明此标准拥有行业选择能力。

“净流入比率”指标回测中，非等权买入整体优于等权买入，但无法持续获得超额收益，故剔除。

“流入”指标回测中，等权买入整体优于非等权买入。前期跑不过基准，后期也没有明显的超额收益能力，故剔除。

“流入比率”指标回测中，无论是等权还是非等权买入均无法取得超额收益，故剔除。

综上所述，仅“净流入”指标无论在周频调整还是月频调整中都表现优异，因此选取“净流入”指标作为代表主动资金面的反映指标。

4. 周期选择

对四种指标的不同周期数据进行回测分析，获取在不同周期下的评价指标。如下表所示：

表 2.4 指标数据分析

指标	夏普比率	最大回撤	收益率（非等权）	跑赢市场期数
流入（周）	-0.419	37.6%	1.200	60
净流入（周）	0.762	25.8%	1.857	213
流入（月）	-0.651	39.3%	1.171	14
净流入（月）	0.495	23.3%	1.416	42

在不同周期中，“净流入”指标在周度、月度下的表现均好于同周期的“流入”指标，原因可能是“净流入”剔除了“流入”指标中资金流出的因素，使得资金流入指标更加纯粹，更加充分反映市场资金的情绪。

在相同周期中，“净流入”指标周度数据优于月度数据，但是结合北向资金的周期选择，我们最终选定以“净流入”指标的月度调整为最终指标。

2.4 复合因子配置行业

在分别探究了采用申万一级 28 个行业分类的北向资金和主动资金能否对行业进行选择后，可以得出两者都具有一定的行业选择能力。本文继而探究将两种资金流结合是否能对行业具有更明显的选择能力。

2.4.1 复合因子设置

我们将在北向资金中选取的持仓规模指标、主动资金中选取的净流入指标按照不同的权重构建出新的复合因子，并计算不同权重下使用该复合因子后的行业收益率、最大回撤和夏普比率，衡量其行业选择能力，同时选择出最优组合权重。

(1) 为了消除指标之间的量纲影响，我们分别将两个指标进行归一化。

$$\text{new data} = \frac{\text{data} - \min}{\max - \min}$$

(2) 我们以 0.05 作为组距，将测试组分为 21 组，北向资金持仓规模指标权重从 0 开始以 0.05 在组间递增，则

$$\text{复合因子值} = w_b * p_b^{\text{new}} + (1 - w_b) * \text{net}_z$$

其中， w_b 为北向资金权重， p_b^{new} 为归一化后北向资金持仓规模， net_z 为归一化后主动资金净流入指标

(3) 第 1 组完全按照主动资金净流入指标（北向资金持仓规模指标权重为 0），第 21 组则完全按照北向资金持仓规模指标（北向资金持仓规模指标权重为 1），将此两组作为对照组。在每一组权重下，2017 年 1 月 1 日至 2021 年 7 月 16 日间，以月为调仓频率（无手续费），选择上一期复合因子值最大的 top5 行业分别进行等权和非等权买入。

2.4.2 复合因子组合权重测试

(1) 各组结果




图 2.9 不同权重对比

在不同的组合权重下，非等权多头组合收益（蓝线）基本高于等权多头收益（红线），说明排名靠前的行业有更好的收益，同时也再次证明资金指标具备行

业选择能力。

(2) 最优组回测结果

在 21 组中，回测所得收益率最高的是第 17 组，即北向资金持仓规模指标权重为 0.85 的组别。其回测结果如下图所示：




图 2.10 北向资金占比为 0.85 多头组合收益

表 2.5 回测结果分析

等权买入收益率	1.728
非等权买入收益率	2.007
夏普比率	1.015
最大回撤	0.299

以 0.85 为北向资金持股比例指标权重，0.15 为主动资金净流入指标权重，构建的复合因子具有更好的收益率表现，最终选定以北向资金权重 0.85，主动资金权重 0.15 构建资金复合指标。

3. 基于 SVR 算法的多因子模型选股

3.1 多因子模型构建

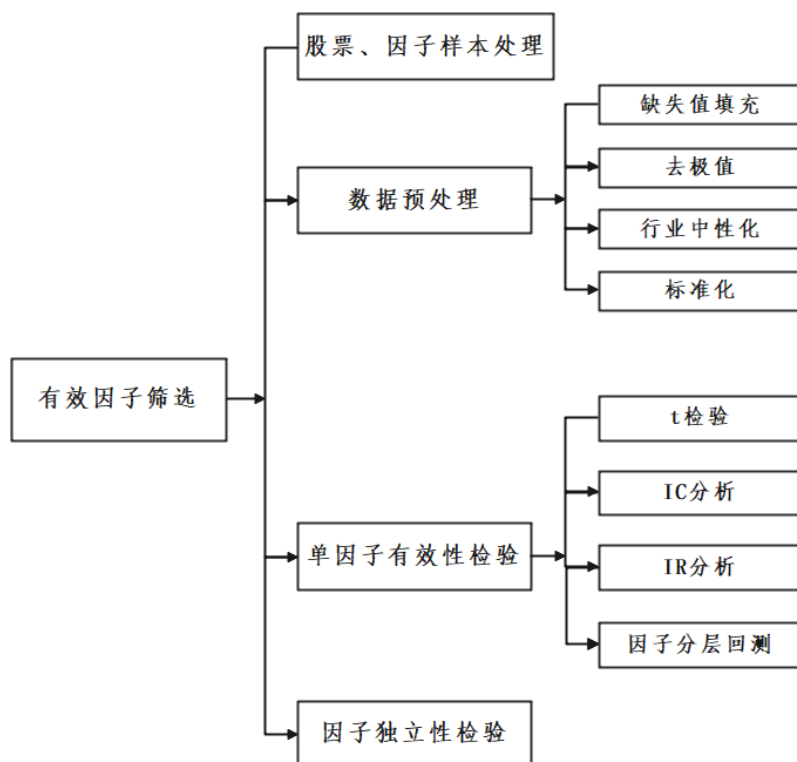


图 3.1 有效因子筛选流程

在用 SVR 机器学习算法进行多因子选股前，需在众多因子中筛选出与股票价格最为相关、稳定性最好、分层效果明显的有效因子。最后，需要去除影响研究结果准确性的冗余因子，才能得到最佳的因子组合。

选择沪市 300、深市 300 作为 benchmark 资产池，寻找最优因子组合。

本文选用各因子值的样本区间为 2015 年 1 月 1 日至 2019 年 12 月 31 日，共计 60 个月。期间中国股市完成了周期演变，这有利于更好地检测出各因子的有效性。

为了有效减小组合的风险，提高可靠性，其中剔除了 ST、停牌、财务状况等原因，产生的原始数据缺失的股票。

3.1.1 因子样本选择

为了确保因子有效性及算法质量，本报告从不同的维度进行选择，构建因子池。选定沪市 300 与深市 300 做为股票样本，从 240 个因子中，剔除数据大量缺失的 75 个因子，得到 165 个候选因子，表如下：

表 3.1 候选因子表

维度	指标
动量类因子	收盘价格与日期线性回归系数, 1-过去一个月收益率排名与股票总数的比值, 终极指标 TRIx, 当前股价除以过去一个月股价均值-1, CR 指标, 梅斯线, 乖离率, 终极指标 TRIx, 顺势指标, 变动速率
风险类因子	收益方差, 市值因子, 非线性市值因子, 市值立方因子, 对数总市值, 相对强弱, 动量因子, 残差历史波动率, 残差波动因子, BETA, RAW BETA, 日收益率标准差, 个股收益的偏度, 个股收益的峰度
基础科目及衍生类因子	市值, 经营性资产, 流通市值, 管理费用 TTM, 资产减值损失 TTM, 息税折旧摊销前利润, 留存收益, 息税前利润, 净利润 TTM, 经营活动净收益, 金融资产, 营业利润 TTM, 净债务, 营收市值比, 投资活动现金流量净额 TTM, 非经常性损益, 现金流市值比
技术指标因子	指数移动均线, 移动均线, 资金流量指标, 不复权价格因子, 下轨线 (布林线) 指标, 上轨线指标
情绪类因子	成交金额标准差, 成交金额移动平均值, 资金流量, 成交量标准差, 成交量的指数移动平均, 成交量的移动平均值, 20 日平均换手率与 120 日平均换手率之比, 成交量震荡, 平均换手率
质量类因子	权益回报率 TTM, 资产回报率 TTM, 总资产报酬率, 市场杠杆, 应付账款周转率, 销售成本率, 总资产周转率, 无形资产比率, 企业的营业收入利润率, 营业利润率, 销售利润率 TTM, 股东权益比率, 销售净利率, 债务总资产比, 股东权益周转率, 销售税金率, 有形净值债务率, 股东权益与固定资产比率

3.1.2 数据预处理

1. 缺失值填充

在数据处理时, 有些因子存在缺失值, 例如股票停牌等情况, 影响因子的整体检验。本文缺失值采用以上一期有效数据进行填充的方式, 减小数据偏差。

2. 采用 3σ 原则去极值

极端值会严重干扰模型，我们采取 3σ 去极值的方法。

处理逻辑如下：

- (1) 计算因子的平均值与标准差，确认参数 n (这里选定 $n=3$)
- (2) 确认因子值的合理范围为 $[\mu - n\sigma, \mu + n\sigma]$ ，并对因子值作如下的调整：

$$x'_i = \begin{cases} \mu + 3\sigma & \text{if } x_i > \mu + 3\sigma \\ \mu - 3\sigma & \text{if } x_i < \mu - 3\sigma \\ x_i & \text{if } \mu - 3\sigma < x_i < \mu + 3\sigma \end{cases}$$

其中， $\mu = \frac{\sum_{i=1}^n x_i}{n}$ 为某横截面上所有股票因子 x_i 的平均数，

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (x_i - \mu)^2}{n}}$$

，为所有股票因子 x_i 的标准差。

3. 标准化处理

利用因子进行评价，需要将各个因子数据转化为无量纲的纯数值，便于不同单位或量级的指标能够送入模型训练。本策略采用 Z-score 标准化方法，将数据统一映射到一致量级区间。

Z-Score 通过 $(x - \mu)/s$ 使得数据标准统一化，提高了数据可比性，削弱了数据解释性。

需要对因子 x_1, x_2, \dots, x_n 进行如下的变化：

$$y_i = \frac{x_i - \mu}{s}$$

$$\text{其中, } \mu = \frac{\sum_{i=1}^n x_i}{n} \quad s = \sqrt{\frac{\sum_{i=1}^n (x_i - \mu)^2}{n-1}}$$

得到的新因子 y_1, y_2, \dots, y_n 的均值为 0，方差为 1，消去了量纲的影响。

3.1.3 单因子有效性检验

1. t 检验

在传统 t 检验分析中，常规的 OLS 回归方法有几大重要的假设前提，误差项均值为零，误差项同方差性。但是，在金融时间序列中，金融资产的回报率常常不能满足同方差的假设，回归方程也不再具有预测能力，传统的基于最小二乘的回归方法将不再适用。

本文采用加权最小二乘回归（WLS）的方法，将流通市值平方根作为回归权重，更加符合金融时间序列的异方差特性，一定程度上解决异方差的问题，使得回归效果更贴近真实数据。

表 3.2 因子 t 值

因子名称	T 值	因子名称	T 值	因子名称	T 值
资产负债率	1.63	20 日顺势指标	1.66	市值立方因子	1.86
CR 指标	1.76	12 日指数移动均线	1.49	动量因子	1.46
60 日收益方差	1.80	120 日指数移动均线	1.50	6 日成交金额标准差	1.52
120 日移动均线	1.47	应付账款周转率	1.54	流动性因子	1.65
BBI 动量	1.68	留存收益	1.53	市值因子	1.74
净债务	1.40	20 日成交量标准差	1.87	杠杆因子	1.63
5 日指数移动均线	1.66	个股收益的 120 日峰度	1.71	BETA	1.73
经营性资产	1.54	股东权益比率	1.65	26 日指数移动均线	1.41
...		
现金流市值比	1.60	销售利润率 TTM	1.57	对数总市值	1.63
不复权价格因子	1.77	5 日乖离率	1.49	盈利预期因子	1.70
市值	1.44	成长因子	1.51	每股营业利润 TTM	1.74
成交量震荡	1.39	营业总成本 TTM	1.37	市场杠杆	1.75

净利润 TTM	1.26	10 日移动均线	1.50	个股收益 120 日偏度	1.39
---------	------	----------	------	--------------	------

通过对 t 值数据进行分位数计算，可以得到 t 值的数据结构，如下表：

表 3.3 t 值分位数数据

最小值	1/4 分位	中值	3/4 分位	最大值
0.88	1.72	2.19	2.51	3.55

根据一般的正态分布数据的概率密度，当 t 检验达到 1.96 时，我们说回归系数在 5%的置信水平下显著。我们在此基础上，结合本文的数据结构，保证后续因子检验的可靠性，同时不错过高性能因子，将序列均值 1.96 作为 t 值筛选的最终标准。

最终筛选出 106 个 t 值显著的因子，等待下一步筛选。

2. IC 分析

IC 法是业界投资研究中单因子有效性检验常用的方法，因子在第 T 期的 IC 值是指因子在第 T 期的暴露度向量与 T+1 期的个股收益率向量的相关系数：

$$\text{公式: } IC^T = \text{corr}(r^{T+1}, X^T)$$

r^{T+1} ：所有个股在第 T+1 期的收益率

X^T ：所有个股第 T 期在被测单因子上的暴露度

IC 法模型构建方法如下：

- (1) 在训练集的每一期初始，对于每个因子，得到全部股票该因子值的序列；
- (2) 计算全部股票未来两个月的收益序列，求这两个序列的 pearson 相关系数；
- (3) 用训练集所有期相关系数的平均值作为判断标准。

调仓周期的选择：

本策略选用 20 个交易日（30 天）作为调仓周期。

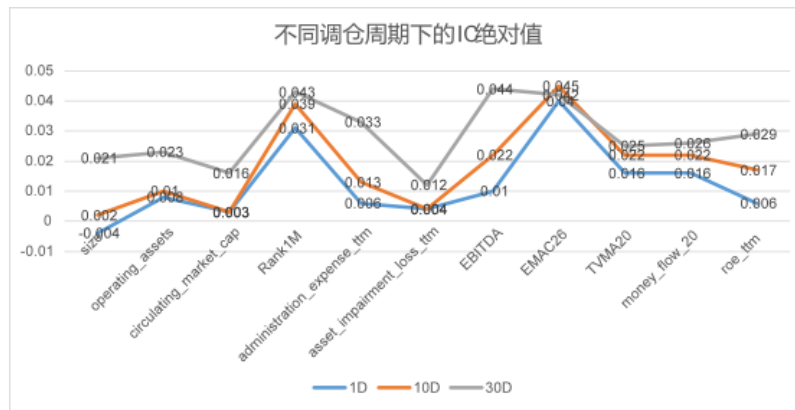


图 3.2 不同调仓周期下的 IC 绝对值

本文选用 1、10、30 个交易日作为观测周期。根据不同观察周期所展示的数据，可以明显观察到，30 日为周期的因子 IC 折线明显处于最高位。由于日度、周度数据中存在着较大的市场波动，在一定程度上不能良好的解释股价或者是市场走势，同时结合上述数据，最终，我们采用 IC 值更高，拟合效果更好的月度数据，作为 IC 分析的观察周期。

因子评价方法：

因子的相关系数 IC 均值的绝对值越大，表明该因子与未来收益的解释力越强。为避免因子类型的单一，从不同大类中进行筛选，选取每一大类因子中 IC 绝对值靠前的因子。最终挑选出 14 个因子如下表所示：

表 3.4 不同类因子的 IC 绝对值

因子类型	因子名称	IC 均值序列绝对值
动量类因子	24 日收盘价格与日期线性回归系数	0.034
	1-（过去一个月收益率排名/股票总数）	0.032
风险类因子	个股收益的 120 日峰度	0.041
基础科目及衍生类	每股营业利润	0.058
	每股未分配利润	0.055
	每股留存收益	0.054
	每股收益 TTM	0.051
	利润市值比	0.035

	市值	0.031
技术指标因子	不复权价格因子	0.022
	60 日移动均线	0.019
	下轨线（布林线）指标	0.017
情绪类因子	10 日平均换手率	0.055
	20 日成交金额的标准差	0.033

参考业界常用标准，本篇论文 IC 法标准如下：

因子 IC 值均值的绝对值大于 0.03 则认为该因子对于下期收益率具有预测效果，可以加入模型因子池，反之则剔除该因子。结合 Alphalens 工具，对因子 IC 进行分析，以下仅展示部分因子分析结果：

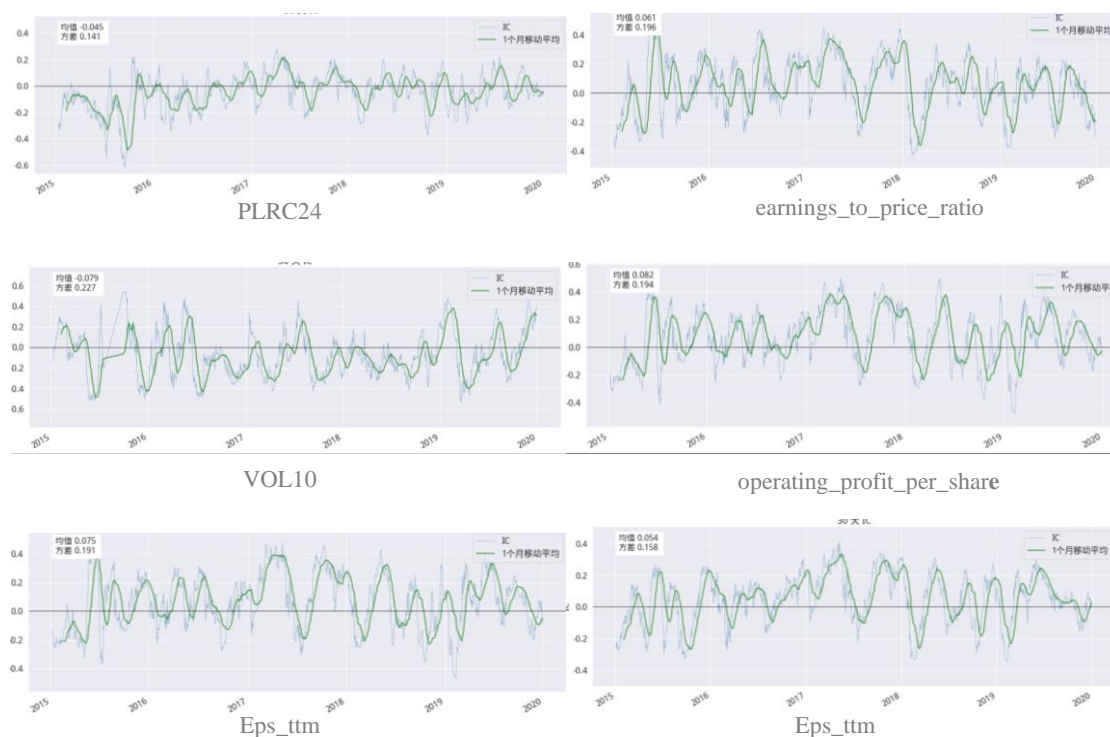


图 3.3 部分因子 IC 序列情况

其中，IC 均值为正的因子被称为正向因子，与收益率呈正相关；IC 均值为负的因子被称为负向因子，与收益率呈负相关。

经过本轮筛选，剔除 IC 绝对值小于 0.03 的因子后，得到 7 个 t 值绝对值大于 1.96，IC 值序列绝对值大于 0.03 的有效因子。“市值”“每股收益”“利润

市值比”“每股营业利润”为正向因子；“24 日收盘价格与日期线性回归系数”“10 日平均换手率”“20 日成交金额的标准差”为负向因子。

3. IR 分析

计算 IR 即信息比率，是超额收益的均值与标准差之比。

$$\text{IR 计算公式: } IR \approx \frac{IC_t}{Std(IC_t)}$$

根据以上 t 值、IC、IR 指标筛选之后，从众多因子之中，挑选出 7 个精选因子，下一步对这 7 个因子进行进一步的分析。

表 3.5 挑选出的因子名称

因子缩写	因子名称	IC 绝对值
PLRC24	24 日收盘价与日期的线性回归系数	0.033
earnings_to_price_ratio	利润市值比	0.035
operating_profit_per_share	每股营业利润	0.058
VOL10	10 日平均换手率	0.055
TVSTD20	20 日成交金额的标准差	0.033
Size	市值	0.031
Rank1M	1-（上一个月收益率排名/股票总数）	0.032

其中，“24 日收盘价格与日期线性回归系数”因子，是由处理后过去 24 日收盘价格与日期序号的线性回归系数，其具体构建方式是：

$$\frac{close_t}{mean(close_t)} = \beta * t + \alpha$$

4. 因子分层回测

因子分层回测法从因子值对于个股的区分度出发，每一期按照因子值的大小对个股进行排序分组，将资产池中的股票分为 10 组，统计各组的累计收益、最大回撤、信息比率等指标。观察组间收益率曲线是否就有良好的分层现象，分组

后各组尤其是优势组和劣势组之间表现出来差异性和单调性越强,说明该因子对于股票的区分能力越强。理想状态下,做多优势组即可获取良好的收益。

调仓周期:

调仓周期为 20 个交易日 (30 天)。在每个调仓周期开始前,计算上一期所有股票的因子值,将所有个股按因子排序平均分成十分位,每分位个股按照调仓周期第一个交易日的开盘价等权买入。

因子评价方法: 本篇论文选取分位数累计对数收益图作为分层回测法评价指标。若各组之间分层效果明显,能够简单判断因子和收益率之前是否有着单调性关系,则认为该因子对于股票有明显的区分能力,可以加入模型因子池,若各组之间收益曲线黏连,没有明显区分度,则剔除该因子。

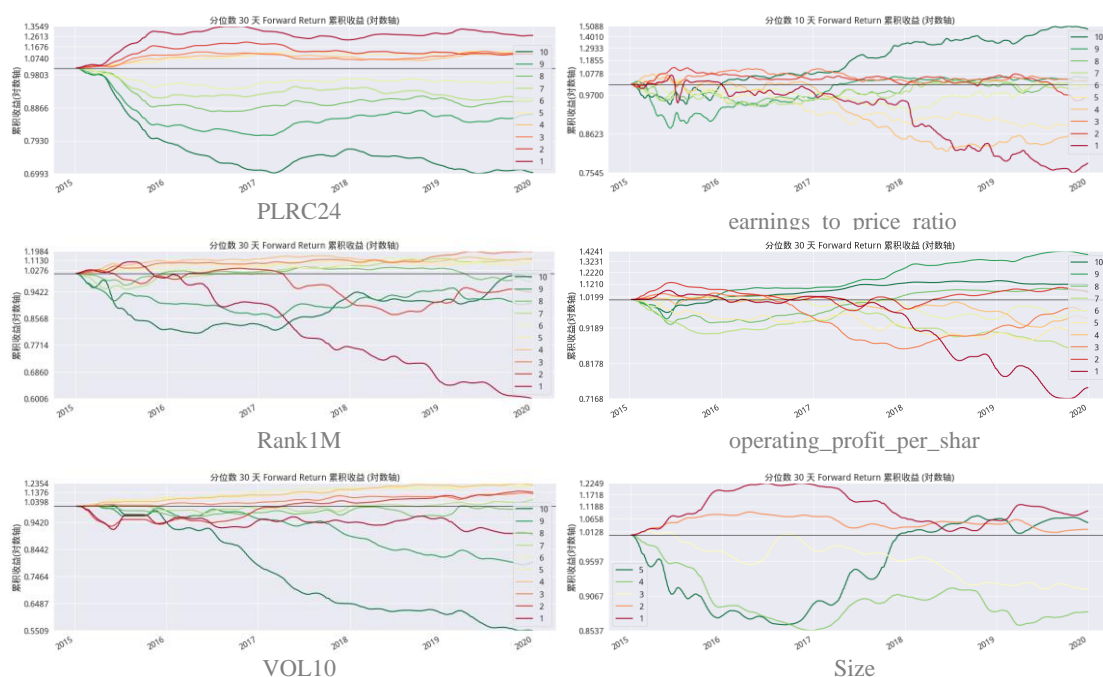


图 3.4 因子分层效果检测

对于负向因子‘PLRC24’,8-10组为优势组,1-3组为为劣势组,上图显示,第1组累计收益最低,第10组累计收益最高,且优势组与劣势组在组内有一定的相关性,在组间有明显的差异性,10组累计收益率曲线无粘连,有良好的分层效果。

对于“1-过去一个月收益率排名与股票总数的比值”(Rank1M)因子,可以观察到,10组分位数收益曲线中,各组收益曲线之间黏合性较强,无明显的分

层效果,且未展现出收益曲线转折的现象,说明因子效果并没有出现反转的情况。故剔除该因子。

同理的,市值因子与 Rank1M 因子情况相似,分层回测曲线粘合,无良好的分层效果,故剔除市值因子。




图 3.5 反转特例

对于利润市值比 ('earnings_to_price_ratio') 因子,如图 2.20 在 2015 年初到 2016 初年间,第 1 组为优势组,第 10 组是劣势组,但是在 2016 中年到 2019 年,优劣势组发生反转,但反转并不完全。原第一组优势组成为劣势组,原第十组劣势组逆转成为优势组。但是反转后仍有粘合,故剔除该因子。

经过本轮因子收益、分层回测分析后,剔除 3 个因子,分别为市值 size、利润市值比因子、每股收益 ttm,剩余 4 个因子进入下一轮检验。

3.1.4 因子独立性检验

在上述的因子有效性筛选中,我们共筛选出 4 个与股票价格相关性很强的“有效因子”,但由于这些有效因子之间并非完全独立,它们之间还存在着或高或低的相关性,这些因子也被称为“冗余因子”。冗余因子会对策略产生不良影响。因此须去除冗余因子,得到“有效因子组合”。

因子独立性检验的思路为:

- (1) 计算 4 个有效因子之间的相关系数；
- (2) 对剩余因子进行分级筛选，找出相关性高于 0.3 的“冗余因子对”；
- (3) 计算“冗余因子对”中两个因子的 IC 值，高 IC 的予以保留，低 IC 的舍去。




图 3.6 因子相关系数矩阵

通过相关系数热力矩阵可以看到，剩余的 4 个因子之间，最高相关性 0.24，相关性低于 0.3 时，我们认为两者之间不具有明显的相关性，所以，最终选定 4 个因子如下表所示：

表 3.6 最终选定因子表

因子缩写	因子名称	IC 绝对值	因子方向
PLRC24	24 日收盘价与日期回归系数	0.033	负向
VOL10	10 日平均换手率	0.055	负向
TVSTD20	20 日成交金额的标准差	0.033	负向
operating_profit_per_share	每股营业利润	0.059	正向

3.2 基于 SVR 算法的多因子模型构建

3.2.1 算法简介

支持向量机是一种在针对 ANN 神经网络诸多缺陷而提出的一种机器学习模型，由于其分类效果明显，计算简单，现在已成为国内外学者进行数据挖掘广泛使用的工具。支持向量用于回归，形成了 SVR（支持向量回归）。本文将 SVR

应用到量化选股上，建立回归预测模型，最终可把有投资价值的股票挑选出来。

3.2.2 算法的理论

对样本 (x, y) ，传统回归模型通常当且仅当 $f(x)$ 完全等于 y 时，损失才为零。与此不同，SVR 以 $f(x)$ 为中心构造了一个“间隔带”，对于间隔带内的样本，都不计算损失；只有间隔带之外的，才计入损失函数。

具体地， $K(x, z)$ 是一个函数，意味着存在一个从输入空间到特征空间的映射 $\phi(x)$ ，对任意输入空间中的 x, z ，有：

$$K(x, z) = \phi(x) \cdot \phi(z)$$

在支持向量回归学习的对偶问题中，用核函数 $K(x, z)$ 替代内积，求解得到的就是支持向量回归：

$$f(x) = \sum_{i=1}^m (\alpha_i^* - \alpha_i) x_i^T x + b$$

3.2.3 支持向量回归的理论优势

SVR 本质是采用了支持向量的思想，和拉格朗日乘子式的方式，来对数据进行回归分析，是基于 SVM 的一种回归方法，与其他的机器学习方法相较而言，有很多可圈可点之处，其理论优势主要在于：

(1) 大多是机器学习方法是建立在经验风险最小化的基础之上，在处理数据时容易出现过度拟合的问题，使用模型十分依赖研究者的经验，而 SVR 是基于 VC 维理论和结构风险最小化的原理的，该理论通过对特定训练样本集合的学习精度和泛化能力之间寻找最佳结合点来达到较高的预测精度以及较强的模型适用性。

(2) SVR 作为一种新型的统计方法，其在原理上并不涉及概率测度以及大数定律等法则，通过从源头上避开了“归纳-演绎”传统预测的步骤来实现训练样本到预测样本的“转导推理”，大大简化了预测过程中的推理学习过程。

(3) 经理论研究表明，只要支持向量机特征层的维数足够高，就能够逼近

任意的非线性映射关系，另一方面，使用正确合适的核函数可以有效避免特征层高维数带来复杂计算的问题。

3.2.4 模型实现

为了抓住市场风格的转变，及时调整模型的风格偏向。模型每 252 个交易日训练一次：本文采用 2015 年至 2019 年的过去 60 个月度数据进行参数调优，将训练完毕后的新模型作为未来的选股模型。

具体参数调优过程如下：

对于 SVR 回归模型的参数，本文主要选取惩罚函数、核函数类型、核函数系数三个关键参数进行调优。具体做法为在每次调参时，指定惩罚函数 C 参数候选序列为 [0.001, 0.01, 0.1, 1.0, 10.0, 100.0]，核函数类型参数候选序列为 ['linear', 'poly', 'rbf', 'sigmoid']，指定核函数系数 gamma 参数候选序列为 [0.001, 0.01, 0.1, 1, 10, 100, 1000]，选取正确率作为得分函数来评判参数优劣。

3.2.5 模型选股实际运用

首先将已经处理好的数据分为学习集和预测集和验证集。将 15-19 年的 27849 条收益率数据、83684 条因子值数据归为学习集，20 年的 15195 条因子值数据作为预测集，20 年的 5065 条收益率数据作为验证集。为了避免使用未来数据，20 年的收益率数据只会作为验证模型有效性和计算正确率使用，不会加入训练集。

其次，我们将标准化后的因子值作为 SVR 模型的自变量，收益率值作为因变量，每一条因子值对应下一月度的收益率，进行模型训练。该预测模型可通过股票因子值预测未来的股票收益率。

然后，我们将 20 年的因子值传入训练好的模型，得到股票预测收益率，将其与验证集比较，计算均方误差 MSE 和绝对误差 MAE 对模型进行评估，得到均方误差为 0.0169、绝对误差为 0.0884。

再者，我们分别对每一周期股票实际收益率和预测收益率进行收益率排名，计算预测收益率前 10 占实际收益率前 10、前 20、前 47、前 94 的比例，对 20 年验证集的 11 个月度周期求均值，得到以下结果：

表 3.7 SVR 模型结果

占数	前 10	前 20	前 47	前 94
比例	20%	33.3%	39.1%	60%

从以上结论可以看出，SVR 模型拥有一定的正确率，能够为使用者提供准确的预测结果，从而得出合理的投资组合。

4. 利用 RSRS 判断阻力支撑状况的择时策略

4.1 相关概念

RSRS（阻力支撑相对强度）指数是由光大证券提出的这一择时方法，认为阻力和支撑位是相对变化的，而且阻力和支撑位之间也有强弱关系。

如果阻力位强度强于支撑位，则市场倾向于下跌从而卖出所持股票；如果支撑位强度强于阻力位，则市场倾向于上涨从而开仓买入股票；当处于震荡时期，阻力和支撑位没有明显的强弱关系，则在向上突破的时候做多，向下突破的时候卖出或者空仓。

在平常的投资中，类似的，还有布林带轨道、麦克指标或者薛氏通道来衡量目前股价处于什么位置。但是，以布林线为例，在市场震荡的时候，布林线指标反复给出信号，造成频繁操作，吞噬投资收益。

4.2 阻力支撑状况

本策略运用了 RSRS 来衡量阻力线和支撑线之间的相对变动情况。本文将每日最高、最低价作为阻力、支撑位，建立最高价和最低价的线性回归模型：

$$high = \alpha + \beta \cdot low + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2)$$

其中， $high$ =股票每日最高价， low =每日最低价，

β =阻力强度和支撑强度的相对大小。

在获取 n 日的最高价和最低价序列之后，把两者进行最小二乘线性回归，得到 β 系数。 β 系数越大，阻力力量相对于支撑力量变强，股价向好； β 系数越小，

阻力力量相对于支撑力量变弱，股价见顶。

(1) 市场在上涨牛市的时候：

若 β 高时，则上方阻力相对于支撑向上移动，对于股票价格来说上涨的空间拓宽，可能会继续上涨。




图 4.1 牛市中高 β 值对应市场走势示例

若 β 低时，则上方阻力相对于支撑向下移动，对于股票价格来说上涨的空间被压缩，上涨的速度可能会减慢。




图 4.2 熊市中高 β 值对应市场走势示例

(2) 市场在震荡中：

两股力量相互纠缠，此时 β 处于平均状态，投资者则不会收到交易指令，避免了频繁交易所带来的高额手续费损失。

而当支撑或者阻力有其中一方力量发生明显增强时，则预示着一轮新的市场行情即将发生。此时则应该根据 β 值确定市场力量，判断出市场情况。

(3) 市场在下跌熊市的时候：

若 β 高时，则下方支撑相对于阻力向上移动，对于股票价格来说下降的空间被压缩，可能会减速甚至停止停止下跌。




图 4.3 牛市中低 beta 值对应市场走势示例

若 β 低时，则下方支撑相对于阻力向下移动，对于股票价格来说下降的空间扩展，可能会加速下跌。




图 4.4 熊市中低 beta 值对应市场走势示例

4.3 策略实现

- 1、获取本日期前 d 日的股票数据信息：最高价 **high** 和最低价 **low** 两个时间序列。
- 2、利用最小二乘线性回归法对 **high** 和 **low** 进行回归，获取回归 β 斜率系数。
- 3、计算此日期前 700 日的 β 标准差和 β 均值，并将本日期的 β 系数标准化。

得到 **RSRS** 指标值：

$$RSRS = \frac{\beta - \bar{\beta}}{\sigma_{\beta}}$$

- 4、开仓信号： $RSRS$ (值) > 0.7 ；

平仓信号： $RSRS$ (值) < -0.7 。

本文的开仓平仓指标设置使用了 700 日均值标准差标准化过的 β ，而非初始 β 。由于市场状况经常发生变化，导致 β 值波动比较大，使用固定的指标去衡量

不同市场状况下的 β 显然是不合适的, 而使用标准化过的 β 能更加灵活地适应整体市场的基本状态。

4.4 参数调整

由于在设置指标的时候有两个可变参数 d (β 回归天数) 和 x (标准化天数), 因此我们进行参数进行了不同的取值进行研究, 以决定最优的参数组合。我们回测的时间为 15-19 年, 标的资产为沪深 300 指数。如下表所示, 当的 $d=18$, $x=700$ 时收益率最高。

表 4.1 参数测试

$x \backslash d$	12	15	18	21
400	14.63%	28.96%	64.09%	23.63%
500	16.62%	33.19%	61.15%	34.72%
600	17.79%	41.92%	72.16%	31.34%
700	23.53%	14.26%	74.15%	43.52%
800	34.89%	17.83%	53.75%	42.71%

4.5 策略效果



图 4.5 择时回测

RSRS 择时策略选回测区间为 2015 年 1 月 1 日至 2019 年 12 月 31 日。策略总收益为 74.15%，总超额收益为 50.22%，年化收益为 12.05%，轻松跑赢大市。且 5 年最大回撤仅为 15.74%，较稳健。开平仓次数为 41 次。

从回测图上可见，在 2015 年 6 月 25 号至 2016 年 1 月 28 号、2018 年全年期间，大市有较大回撤，而本策略表现优异，基本没有获利回吐。而在 17 年 6 月 9 号至 17 年 11 月 22 号期间，大市持续上涨，而本策略也有较好的上涨表现。

5 风险控制优化

5.1 仓位管理与风险控制

受到海龟交易思想的启发，本策略基于市场波动性来进行仓位管理。通过构建 ATR 指标，即平均真实波动 Average True Range，来量化市场或者个股的波动性，根据市场的波动情况每次以 *amount* 为单位加减仓位，达到仓位管理以及风险控制的目的。

ATR 指标的构建方式为：

$$ATR = \frac{\sum \text{Max}(H_{i-1} - L_{i-1}, H - P_{i-2}, P_{i-2} - L_{i-1})}{N}$$

其中， H_{i-1} 表示第 $i-1$ 期的最高价， L_{i-1} 表示第 $i-1$ 期的最低价， P_{i-2} 表示第 $i-2$ 期的收盘价， N 表示 ATR 指标的回溯日期数，一般采用过去上期交易日的前 20 日指标，即 $N = 20$ 。

加减仓单位 *amount* 指标构建：

$$\text{amount} = \frac{x * \text{asset}}{ATR * 100}$$

其中，*asset* 表示总资产， x 代表总资产占比，一般取 1%，使得买入一 *amount* 单位的标的股票，当日的资产波动率不超过 1%， $ATR * 100$ 则表示标的资产的变动单位，一手股票的价格变化量为 $ATR * 100$ 。

(1) 开仓条件：

当 RSRS 指标符合条件时开仓，则买入一 *amount* 单位

(2) 加仓条件:

在 RSRS 择时指标符合条件的同时，判断，若上一交易日收盘价距上一次买入价格上涨了 $0.5ATR$ ，则加仓一个 *amount* 单位。

(3) 减仓条件:

若上一交易日收盘价距上一次买入价格下跌 $0.5ATR$ ，减仓一个 *amount* 单位；若下跌幅度超过 2 倍 ATR ，则全仓卖出该目标股票。

从定义中可以看出，以上一交易日的过去 20 日内最大价格浮动的平均值来衡量市场的波动性，以 0.5 倍该值作为加减仓的触发条件。

5.2 优化结果

对加入风控的择时策略进行回测，与原择时进行对比：




图 5.1 未加风险控制回测图



图 5.2 加入风险控制回测图

表 5.1 风控回测对比表

	超额收益	夏普比率	最大回撤
未加风险控制	33.53%	0.504	19.19%
加入风险控制	40.91%	0.591	15.58%

可以看到，纯 RSRS 择时策略在结合了 ATR 仓位管理和风险控制之后策略超额收益上升 8.42%，有显著的提高。夏普比率从 0.588 上升至 0.676，最大回撤从 15.74% 降至 13.68%，在获得更高超额收益的情况下，进一步控制了最大回撤，说明该风险控制策略显著有效。

6 策略回测：

(1) 短期回测



图 6.1 策略短期回测

我们选定 2020 年 12 月 26 日至 2021 年 6 月 30 日作为短期回测对象，以沪深 300 作为回测基准，得到的回测信息如下：

表 6.1 短期回测表

策略收益	26.13%	Alpha	0.57
基准收益	2.16%	Beta	1.59
超额收益	23.97%	夏普比率	1.19
最大回撤	24.43%	胜率	49.58%

从短期来看，策略有良好表现，有 23.97% 的超额收益。具有 59.58% 的胜率。

(2) 长期回测



图 6.2 长期策略回测

我们选定 2019 年 6 月 27 日至 2021 年 6 月 10 日作为长期策略的回测时间，以沪深 300 作为回测基准。得到的回测信息如下：

表 6.2 长期策略回测表

策略收益	149.16%	Alpha	0.44
基准收益	36.23%	Beta	0.92
超额收益	112.93%	夏普比率	1.48
最大回撤	22.4%	胜率	41.8%

可以看到，不论是短期测试还是长期测试，都可以观察到，策略收益率长期运行于基准收益率自上，能够在不同的周期下跑赢大盘

参考文献

- [1]廖世敏.基于 GRA_SVM 的量化选股策略研究[D]. 硕士学位论文, 成都理工大学, 2019
- [2]陈阳.基于 SVM 的沪深 300 指数涨跌预测及量化策略研究[D]. 硕士学位论文, 西北大学, 2019
- [3]江鹏.基于支持向量机_SVM_股票择时策略的研究[D]. 硕士学位论文, 江西财经大学, 2019
- [4]曹帅.考虑行业因子的 CPP 量化择股策略设计[D]. 硕士学位论文, 上海师范大学
- [5]汪艺锦.基于彼得·林奇投资理念: 叠加择时的选股策略研究[D]. 硕士学位论文, 上海大学悉尼工商学院, 2018
- [6]吴海韬.基于 RSRS 择时指标的量化投资选股多因子模型优化研究[D]. 硕士学位论文, 广西大学, 2019
- [7]光大证券.基于阻力支撑相对强度 (RSRS) 的市场择时, 2017
- [8]申万宏源研究.机器学习合成非线性因子, 增强效果如何? 2020
- [9]蔡丽.“北上资金”真的是聪明钱吗? ——基于 A 股上市公司的实证研究[J]. 中国物价
- [10]广发证券.多因子 Alpha 系列报告之(三十七): 探寻资金流背后的风格轮动规律, 2018
- [11]安信证券.金融工程主题报告: 北向资金交易能力一定强吗, 2020
- [12]渤海证券.北向资金专题系列之一: 基于北向资金持仓的量化选股策略, 2021
- [13]何晟.基于北上资金持仓交易行为的多因子选股策略研究[D]. 硕士学位论文, 上海师范大学, 2021

附录